المندوبية السامية للتخطيط
HAUT-COMMISSARIAT AU PLAN

INSEA

Institut National de Statistique et d'Économie Appliquée

Master Systèmes d'Information et Systèmes Intelligents (M2SI)

Année universitaire 2026–2027

RAPPORT DE MINI-PROJET

VISION PAR ORDINATEUR

Classification de l'occupation du sol à partir d'images satellites

Étude comparative de k-NN, Softmax et CNN sur EuroSAT RGB

Réalisé par :

LAASSRIA Abdellah
KAIROUCH Zakaria
BOUITA Yassir

Encadré par :

Pr. EL AMRAOUI Khalid

Sommaire

1 Introduction **2**

2 Dataset et prétraitement **2**

2.1 Présentation des données 2

2.2 Prétraitement 2

2.3 Séparation des données 2

3 Méthodologie et modèles **3**

3.1 Classification par k-NN 3

3.2 Classifieur linéaire Softmax 4

3.3 Réseau de neurones convolutif 4

4 Résultats expérimentaux **4**

4.1 Résultats sur Validation 4

4.2 Courbes d'apprentissage du Softmax 5

4.3 Courbes d'apprentissage du CNN 5

4.4 Évaluation finale sur Test 6

4.5 Matrices de confusion 6

5 Analyse et discussion **7**

5.1 Comparaison des approches 7

5.2 Analyse des erreurs 7

5.3 Limites de l'étude 7

6 Conclusion et perspectives **8**

Références **8**

1. Introduction

La vision par ordinateur est un domaine de l'intelligence artificielle qui permet d'analyser et d'interpréter automatiquement des images. Elle intervient notamment dans la médecine, l'agriculture, la surveillance environnementale et l'analyse d'images satellites.

En télédétection, la classification d'images satellites permet d'identifier différents types d'occupation du sol, comme les forêts, les zones résidentielles et les cours d'eau. Cette tâche présente un intérêt pour l'observation et l'analyse des territoires.

Ce mini-projet étudie trois méthodes de classification supervisée appliquées au dataset **EuroSAT RGB** : **k-Nearest Neighbors (k-NN)**, un **classifieur linéaire Softmax** et un **réseau de neurones convolutif (CNN)**.

L'objectif est de comparer leurs performances et d'étudier l'apport de l'apprentissage de caractéristiques spatiales dans la reconnaissance d'images satellites.

Pour cela, un sous-ensemble équilibré de 900 images appartenant à trois classes a été préparé. Les modèles ont été évalués à l'aide de l'Accuracy, de la Precision, du Recall, du F1-score et des matrices de confusion.

Le rapport présente la préparation des données, les méthodes implémentées, les résultats expérimentaux, leur analyse et les principales limites de cette étude.

2. Dataset et prétraitement

2.1 Présentation des données

EuroSAT RGB est un dataset d'images satellites issues de Sentinel-2, destiné à la classification de l'occupation du sol. Les images originales possèdent une résolution de 64×64 pixels et trois canaux visibles : rouge, vert et bleu.

Les données ont été téléchargées depuis le dépôt Zenodo d'EuroSAT et traitées dans Google Colab.

Trois classes ont été sélectionnées : *Forest*, *Residential* et *River*. Un échantillonnage aléatoire avec une graine fixée à 42 a permis de retenir 300 images par classe, soit 900 images au total.

Table 1 – Classes sélectionnées

ID	Classe	Description	Images
0	Forest	Zones forestières	300
1	Residential	Zones résidentielles	300
2	River	Cours d'eau	300
		Total	**900**

2.2 Prétraitement

Chaque image a été convertie en RGB, redimensionnée à 32×32 pixels, puis transformée en tableau NumPy de type `float32`.

Les intensités ont été normalisées dans l'intervalle $[0, 1]$ selon :

$$x_{\text{norm}} = \frac{x}{255}. \tag{1}$$

Chaque image contient ainsi $32 \times 32 \times 3 = 3072$ valeurs numériques. Le redimensionnement réduit le coût de calcul, mais peut entraîner une perte de détails.

2.3 Séparation des données

Une séparation stratifiée a été réalisée afin de conserver la même proportion de chaque classe dans les trois ensembles.

L'ensemble Train sert à l'apprentissage. Validation permet de choisir les hyperparamètres et les meilleurs poids. Test est réservé à l'évaluation finale. Aucune validation croisée n'a été réalisée.

Pour k-NN et Softmax, les images ont été aplaties en vecteurs de 3072 valeurs. Le CNN utilise directement les tenseurs $32 \times 32 \times 3$, afin de conserver leur organisation spatiale.



Figure 1 – Exemples d'images des classes Forest, Residential et River.

Table 2 – Répartition des données

Ensemble	Part	Images	Par classe
Train	60 %	540	180
Validation	20 %	180	60
Test	20 %	180	60
Total	**100 %**	**900**	**300**

3. Méthodologie et modèles

3.1 Classification par k-NN

L'algorithme k-Nearest Neighbors classe une observation à partir des classes de ses K voisins les plus proches. Les images sont représentées par des vecteurs de 3072 caractéristiques. Deux distances ont été comparées :

$$d_{L1}(x, y) = \sum_{i=1}^{3072} |x_i - y_i|, \tag{2}$$

$$d_{L2}(x, y) = \sqrt{\sum_{i=1}^{3072} (x_i - y_i)^2}. \tag{3}$$

Les valeurs $K \in \{1, 3, 5, 7, 9\}$ ont été testées avec les distances Manhattan (L1) et euclidienne (L2).

La meilleure configuration a été sélectionnée selon l'Accuracy sur Validation : $K = 1$**, distance L1**, avec **81,11 %**.

3.2 Classifieur linéaire Softmax

Le deuxième modèle est un réseau sans couche cachée, composé d'une entrée de 3072 valeurs et d'une couche Dense de trois neurones avec activation Softmax.

Pour une classe j, la fonction Softmax s'écrit :

$$P(y = j \mid x) = \frac{e^{z_j}}{\sum_{k=1}^{3} e^{z_k}}, \qquad z = Wx + b. \tag{4}$$

Dans cette formulation, W représente la matrice des poids appris, b le vecteur des biais et $z = Wx + b$ les scores linéaires associés aux trois classes. La fonction Softmax transforme ces scores en probabilités dont la somme vaut 1. La classe prédite est obtenue par $\arg\max_j P(y = j \mid x)$, c'est-à-dire la classe ayant le score le plus élevé.

Le modèle contient **9 219 paramètres** entraînables.

Il a été entraîné pendant 30 époques avec un batch size de 32, l'optimiseur Adam (learning rate 0,001) et la fonction de perte `sparse_categorical_crossentropy`.

Les meilleurs poids ont été sauvegardés selon l'Accuracy Validation, grâce au callback `ModelCheckpoint`.

3.3 Réseau de neurones convolutif

Le CNN exploite les relations spatiales entre les pixels. Les couches de convolution apprennent des motifs visuels locaux, tandis que le MaxPooling réduit les dimensions des cartes de caractéristiques.

L'architecture utilisée est présentée dans le tableau 3.

Table 3 – Architecture du CNN

Couche	Sortie	Paramètres
Input	$(32, 32, 3)$	0
Conv2D (32, 3×3)	$(30, 30, 32)$	896
MaxPooling (2×2)	$(15, 15, 32)$	0
Conv2D (64, 3×3)	$(13, 13, 64)$	18 496
MaxPooling (2×2)	$(6, 6, 64)$	0
Flatten	2304	0
Dense (64, ReLU)	64	147 520
Dense (3, Softmax)	3	195
	Total	**167 107**

Les convolutions et la couche Dense intermédiaire utilisent ReLU. La dernière couche utilise Softmax pour produire les scores des trois classes.

Le CNN a été entraîné avec Adam (learning rate 0,001), la perte `sparse_categorical_crossentropy`, 30 époques et des batchs de 32 images.

Les meilleurs poids ont été conservés selon l'Accuracy Validation. Aucune augmentation de données ni technique de transfer learning n'a été utilisée.

4. Résultats expérimentaux

4.1 Résultats sur Validation

Les hyperparamètres et les meilleurs poids ont été sélectionnés sur l'ensemble Validation, contenant 180 images.

Table 4 – Meilleures performances sur Validation

Modèle	Accuracy	Configuration retenue
k-NN	81,11 %	$K = 1$, Manhattan
Softmax	82,78 %	Époque 21
CNN	94,44 %	Époque 26

Pour le k-NN, la meilleure configuration est obtenue avec $K = 1$ et la distance Manhattan (L1), atteignant

une Accuracy Validation de 81,11 %.

La figure suivante présente l'évolution de l'Accuracy Validation en fonction de K pour les distances L1 et L2.

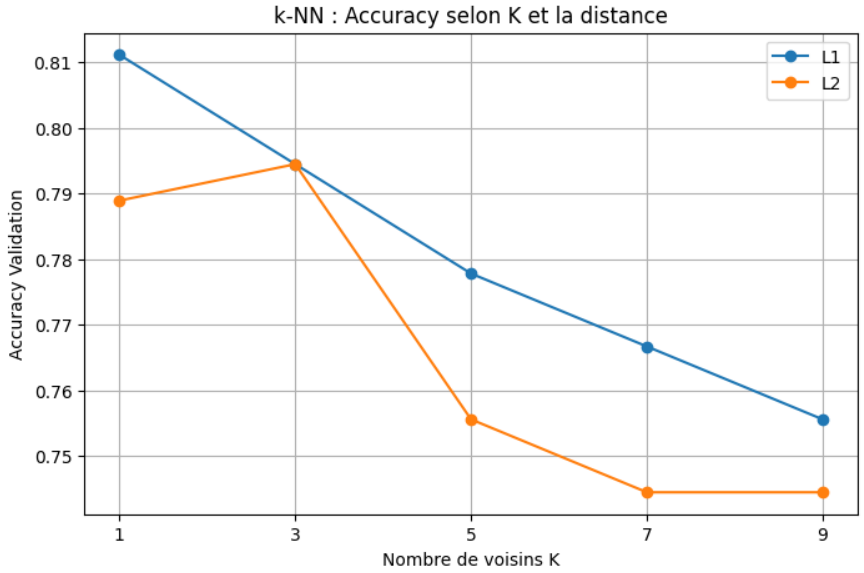


Figure 2 – Accuracy Validation du k-NN en fonction de K, pour les distances L1 et L2.

Pour Softmax, la meilleure Accuracy Validation est atteinte à l'époque 21, avec une perte d'environ 0,4812.

Pour le CNN, la meilleure Accuracy Validation de 94,44 % est atteinte pour la première fois à l'époque 26, avec une perte de 0,1928. Les poids de cette époque ont été retenus par le checkpoint.

4.2 Courbes d'apprentissage du Softmax

Les courbes d'apprentissage du modèle Softmax permettent de suivre l'évolution de l'Accuracy et de la fonction de perte (Loss) sur les ensembles Train et Validation au cours des 30 époques d'entraînement.

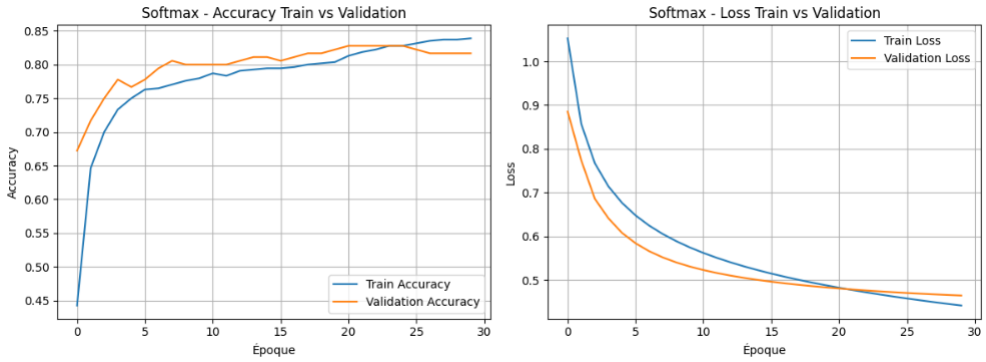


Figure 3 – Courbes d'Accuracy et de Loss du modèle Softmax sur Train et Validation.

Les résultats montrent une augmentation progressive de l'Accuracy et une diminution de la Loss sur les deux ensembles. Les performances s'améliorent principalement durant les premières époques, puis évoluent plus lentement vers une stabilisation.

La meilleure Accuracy Validation atteint 82,78 % à l'époque 21. Les courbes Train et Validation restent relativement proches, sans signe important de surapprentissage sur les 30 époques observées.

4.3 Courbes d'apprentissage du CNN

Les courbes du CNN montrent une progression globale des performances durant les 30 époques. L'Accuracy Train passe de 53,15 % à 96,11 %, tandis que l'Accuracy Validation atteint 94,44 %.

La meilleure Accuracy Validation est atteinte pour la première fois à l'époque 26. Les poids correspondants ont été sauvegardés par `ModelCheckpoint` et utilisés pour l'évaluation finale sur Test.

Les courbes présentent une augmentation progressive de l'Accuracy et une diminution globale de la Loss. Aucun signe important de surapprentissage n'est apparent dans les résultats observés.

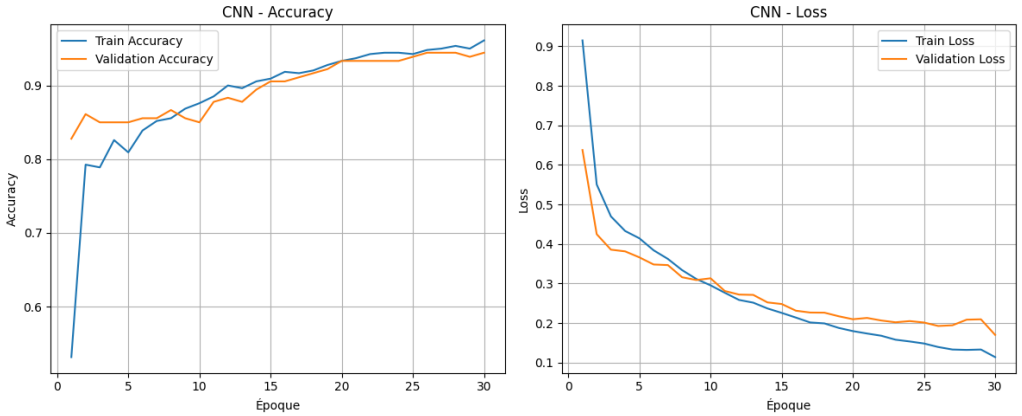


Figure 4 – Courbes d'Accuracy et de Loss du CNN sur Train et Validation.

4.4 Évaluation finale sur Test

Après sélection des configurations sur Validation, les trois modèles ont été évalués sur les mêmes 180 images Test, sans nouvelle optimisation.

Les métriques utilisées sont l'Accuracy, la Precision macro, le Recall macro et le F1-score macro.

Table 5 – Comparaison finale des modèles sur Test

Modèle	Acc.	Prec.	Recall	F1
k-NN	0,7333	0,7402	0,7333	0,7119
Softmax	0,7278	0,7294	0,7278	0,7024
CNN	**0,9167**	**0,9211**	**0,9167**	**0,9167**

Le CNN obtient la meilleure performance, avec 91,67 % d'Accuracy, contre 73,33 % pour k-NN et 72,78 % pour Softmax.

Il classe correctement 165 images sur 180, contre 132 pour k-NN et 131 pour Softmax.

L'amélioration de l'Accuracy du CNN atteint 18,33 points par rapport au k-NN et 18,89 points par rapport à Softmax, sur cet ensemble Test.

4.5 Matrices de confusion

Les matrices de confusion permettent d'identifier les classes correctement reconnues et les principales erreurs. Les lignes correspondent aux vraies classes et les colonnes aux prédictions.

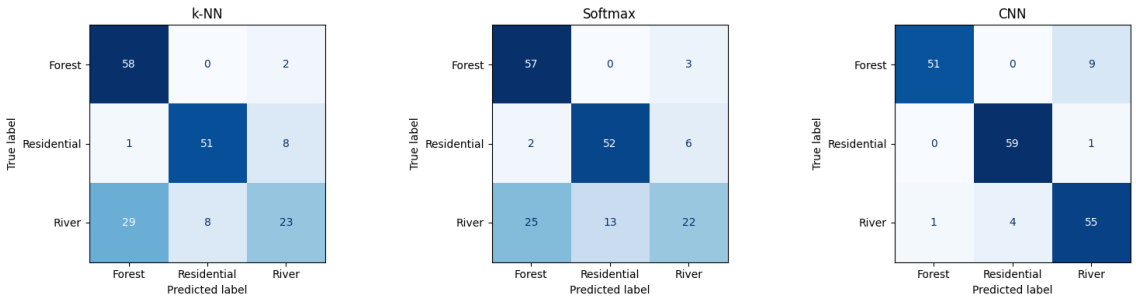


Figure 5 – Matrices de confusion des trois modèles sur l'ensemble Test.

L'analyse des matrices de confusion montre que les performances varient selon les classes.

Les modèles k-NN et Softmax rencontrent principalement des difficultés à reconnaître la classe River, souvent confondue avec Forest ou Residential.

Le CNN reconnaît mieux les classes River et Residential, mais présente davantage de confusions entre Forest et River.

Une comparaison chiffrée des prédictions correctes par classe est présentée dans la section **??**.

5. Analyse et discussion

5.1 Comparaison des approches

Les résultats montrent une différence importante entre les modèles utilisant les pixels aplatis et le réseau de neurones convolutif (CNN).

Le modèle k-NN compare les images dans un espace de 3 072 caractéristiques, sans apprendre de représentation visuelle. Le classifieur Softmax apprend une transformation linéaire des pixels, mais ne dispose pas de couches spécialisées dans l'extraction de motifs spatiaux locaux.

Contrairement aux images représentant un objet isolé, les images satellites décrivent souvent une portion de territoire contenant plusieurs éléments répartis dans l'espace. Une forêt, une rivière ou une zone résidentielle ne correspond donc pas nécessairement à un objet unique et centré.

La classification repose notamment sur la répartition des couleurs, des textures et des motifs locaux. Le CNN est adapté à cette tâche, car il conserve l'organisation spatiale des pixels et apprend progressivement des caractéristiques visuelles grâce aux couches convolutives.

Cette capacité à exploiter les informations spatiales constitue une explication plausible des meilleures performances du CNN, qui atteint 91,67 % d'Accuracy sur Test, contre 73,33 % pour k-NN et 72,78 % pour Softmax.

5.2 Analyse des erreurs

L'analyse des matrices de confusion permet de comparer les performances des trois modèles pour chaque classe. Le tableau 6 présente le nombre d'images correctement classées parmi les 60 images Test de chaque classe.

Table 6 – Prédictions correctes par classe sur Test

Classe réelle	k-NN	Softmax	CNN
Forest	58/60	57/60	51/60
Residential	51/60	52/60	59/60
River	23/60	22/60	55/60
Total	**132/180**	**131/180**	**165/180**

Le CNN améliore nettement la reconnaissance des classes Residential et River, avec respectivement 59 et 55 images correctement classées. En revanche, k-NN et Softmax obtiennent de meilleurs résultats sur Forest.

Au total, le CNN commet 15 erreurs sur les 180 images Test. Sa principale confusion concerne Forest, avec neuf images classées comme River.

Pour illustrer les résultats, trois prédictions correctes et trois erreurs du CNN ont été visualisées.

Parmi les erreurs observées figurent une image River prédite Residential, une image Forest prédite River et une image Residential prédite River.

Ces erreurs peuvent être liées à des ressemblances entre textures, couleurs et structures visuelles, ainsi qu'à la résolution réduite des images.

Il s'agit toutefois d'hypothèses : les visualisations ne permettent pas d'établir avec certitude les causes des erreurs.

5.3 Limites de l'étude

Cette expérimentation présente plusieurs limites :

— Un sous-ensemble de seulement 900 images a été utilisé.

— Trois classes ont été étudiées, au lieu de l'ensemble des classes EuroSAT.

— Le redimensionnement à 32×32 pixels peut supprimer des détails importants.

— Une seule séparation Train/Validation/Test a été réalisée.

— Aucune augmentation de données ni étude sur plusieurs graines aléatoires n'a été effectuée.

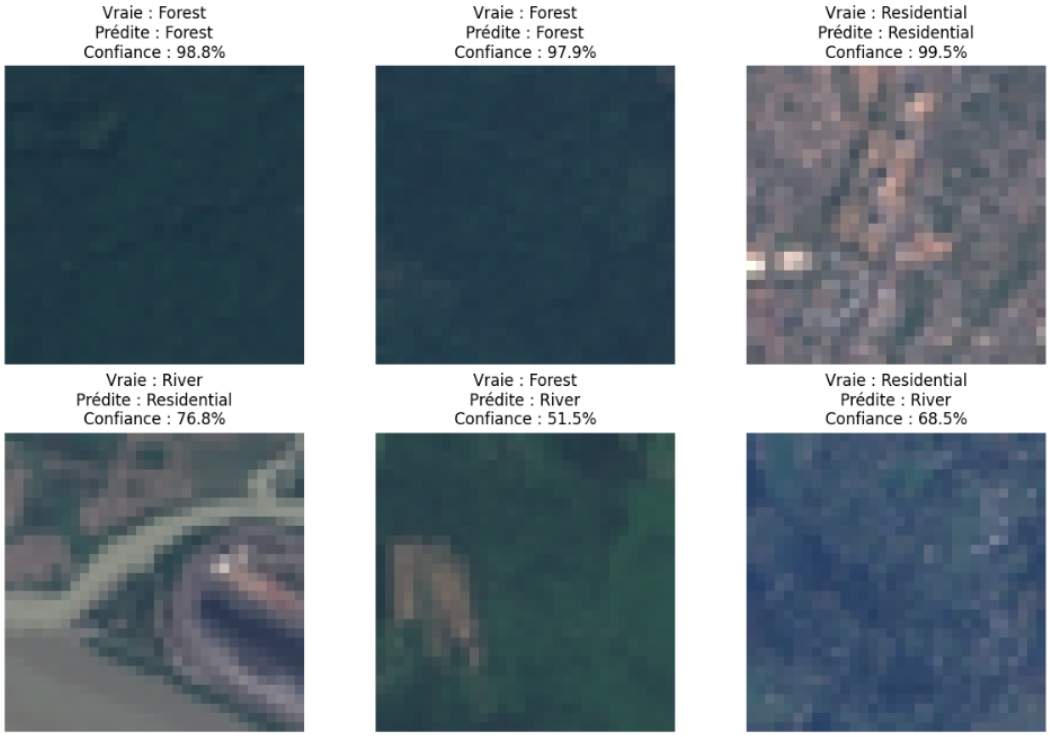


Figure 6 – Exemples de prédictions correctes et incorrectes du CNN.

Les performances obtenues concernent donc le protocole expérimental retenu et ne permettent pas de conclure à une supériorité universelle du CNN.

6. Conclusion et perspectives

Ce mini-projet avait pour objectif de comparer trois approches de classification d'images satellites : k-NN, Softmax et CNN, à partir d'un sous-ensemble équilibré d'EuroSAT RGB.

Après prétraitement et séparation des 900 images, les modèles ont été entraînés et comparés selon un protocole commun.

Les résultats sur Test montrent que le CNN obtient les meilleures performances, avec une Accuracy de **91,67 %** et un F1-score macro de **91,67 %**.

Ces résultats illustrent l'intérêt des couches convolutives pour apprendre des caractéristiques spatiales adaptées à la classification d'images.

Pour prolonger ce travail, il serait intéressant d'étudier davantage de classes, d'utiliser un plus grand nombre d'images, de tester l'augmentation de données et d'évaluer des architectures CNN plus avancées.

Références

[1] EuroSAT RGB, archive du dataset, Zenodo, en ligne : `https://zenodo.org/records/7711810`.

[2] Documentation TensorFlow/Keras : `https://www.tensorflow.org/`.

[3] Documentation Scikit-learn : `https://scikit-learn.org/`.

Liste des tableaux

1 Classes sélectionnées 2
2 Répartition des données 3
3 Architecture du CNN 4
4 Meilleures performances sur Validation 4
5 Comparaison finale des modèles sur Test 6
6 Prédictions correctes par classe sur Test 7

Liste des figures

1 Exemples d'images des classes Forest, Residential et River. 3
2 Accuracy Validation du k-NN en fonction de K, pour les distances L1 et L2. 5
3 Courbes d'Accuracy et de Loss du modèle Softmax sur Train et Validation. 5
4 Courbes d'Accuracy et de Loss du CNN sur Train et Validation. 6
5 Matrices de confusion des trois modèles sur l'ensemble Test. 6
6 Exemples de prédictions correctes et incorrectes du CNN. 8